

1. **Tema y objetivo del proyecto:** El proyecto final se realizará en parejas o grupos de tres personas. Cada grupo elegirá un **tema de interés personal** (sin restricciones de área), y aplicará los conocimientos de inferencia y regresión lineal múltiple usando datos reales.
2. **Dataset: búsqueda y características** El conjunto de datos debe cumplir los siguientes requisitos:
 - Tener al menos **1000 observaciones (filas)**.
 - Incluir como mínimo **6 variables (columnas)**.

Fuentes recomendadas:

- <https://www.kaggle.com/>
 - <https://datasetsearch.research.google.com/>
 - <https://www.openml.org/>
 - <https://ourworldindata.org/>
 - Repositorio UCI
 - Banco Mundial
 - Banco de España
 - Páginas oficiales de instituciones
3. **Selección de la variable objetivo (dependiente)** Deberéis seleccionar una **variable numérica** como variable objetivo (Y) y un conjunto de hasta **10 variables explicativas** (X) que puedan influir sobre ella.
 4. **Aprobación previa del profesor** Antes de comenzar el análisis, debéis subir a Moodle:
 - El archivo del dataset (adjunto).
 - Breve descripción del tema.
 - Propuesta de variable objetivo y variables explicativas.

No se debe empezar el análisis sin la confirmación del profesor.
 5. **Preprocesamiento del dataset** Se espera que deberéis de afrontar algunas de las siguientes tareas para tener resultados válidos, para que lo tengáis en cuenta:
 - Eliminación de valores atípicos.
 - Tratamiento de datos ausentes.
 - Conversión de tipos de datos erróneos.
 - Codificación *one-hot* de variables categóricas.
 6. **Ajuste del modelo de regresión** Se deberá ajustar un modelo de regresión lineal múltiple y justificar lo siguiente:
 - Interpretación de los coeficientes.
 - Inclusión de efectos cuadráticos, logarítmicos e interacciones si procede.
 7. **Validación del modelo** Deberéis verificar los siguientes supuestos:
 - Normalidad de los residuos.
 - Heterocedasticidad.
 - Autocorrelación.

- Multicolinealidad (VIF).

Además, se pedirá un **modelo alternativo más simple**, aunque con menor R^2 ajustado, pero más interpretable.

8. **Conclusiones e insights** El informe debe incluir al menos **5 conclusiones relevantes y prácticas** relacionadas con el contexto elegido.
9. **Presentación y entrega final**
 - Presentación oral de **5 minutos** por grupo.
 - Diapositivas resumen del trabajo.
 - Código empleado.
 - Defensa oral con preguntas.
10. **Ejemplo de propuesta: Fondos de inversión Problema:** entender qué factores explican la rentabilidad de los fondos de inversión. **Datos:**
 - Fuente: `morningstar.com`, `Kaggle` u otra.
 - Datos transversales: cada observación representa un fondo.

Variables:

Nombre	Tipo	^{cc} Rango	Justificación
Rentabilidad anual (%)	Numérica (objetivo)	[-30 %, 60 %]	Variable a explicar
Expense ratio	Numérica	[0.1 %, 3 %]	Altos costes reducen rentabilidad neta
Volatilidad histórica	Numérica	[5 %, 40 %]	Riesgo asociado a mayor rentabilidad esperada
Tamaño del fondo (USD)	Numérica	[10, 100.000]	Tamaños extremos pueden afectar rendimiento
Estilo de inversión	Categórica	[Growth, Value, Blend]	Filosofía de inversión. Se codificará con dummies

Modelo propuesto:

$$\text{Rentabilidad_fondo} = \beta_0 + \beta_1 \cdot \text{Expense_ratio} + \beta_2 \cdot \text{Volatilidad} + \beta_3 \cdot \text{Tamaño_fondo} + \beta_4 \cdot \text{Estilo}$$

Signos esperados:

- $\beta_1 < 0$: mayor coste $\rightarrow$ menor rentabilidad.
- $\beta_2 > 0$: mayor riesgo $\rightarrow$ mayor rentabilidad esperada.
- β_3 : signo incierto.
- β_4 : estilo Growth positivo en años de expansión.

Supuestos del modelo:

- Errores con media cero si se incluyen variables relevantes.
- Heterocedasticidad probable $\rightarrow$ test de White o Breusch-Pagan.
- Exogeneidad plausible si no hay sesgo de selección.
- Autocorrelación: no aplica (datos transversales).
- Comprobación de multicolinealidad.